



MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL
MCDI501: Estadística Computacional para la Toma de Decisiones

Evaluación Formativa 1

Análisis Exploratorio e Inferencial (práctica)

Informe individual o grupal · 0 % (formativa)

Título del proyecto:	Asociaciones con la rotación de empleados
Integrantes:	Hernán Saavedra Lenin Salas Rodrigo Gómez
Dataset:	IBM HR Employee Attrition
Docente:	Jean Paul Maidana
Fecha:	8 de octubre de 2026
Repositorio GitHub:	https://github.com/hernansaavedrag/estadisticaComputacional

1 Introducción

Analizamos el conjunto sintético IBM HR Employee Attrition para explorar asociaciones entre condiciones laborales y salida de empleados. La proporción de salida es 16,12 % y existe asociación con las horas extra en el análisis bivariado. Los resultados constituyen un ejercicio estadístico y no representan evidencia de una empresa real.

La rotación puede afectar la continuidad de los equipos y la planificación de personal. La pregunta del proyecto es qué asociaciones presentan las horas extra, el ingreso mensual, la satisfacción laboral y la antigüedad con la salida de empleados. El objetivo es caracterizar estas variables y evaluar una asociación pertinente como base para discutir decisiones bajo incertidumbre, sin entrenar todavía modelos predictivos.

Ficha del conjunto	Descripción
Fuente	Kaggle, IBM HR Analytics Employee Attrition & Performance
Unidad de observación	Un registro sintético de empleado
Tamaño verificado	1.470 registros y 35 columnas
Variable objetivo	Attrition, Yes / No
Período y población	No se establece un período de seguimiento ni un marco de muestreo de trabajadores reales
Contexto de decisión	Investigación de condiciones laborales y planificación de acciones de retención

El archivo original no contiene faltantes ni filas duplicadas. EmployeeNumber es único. EmployeeCount, Over18 y StandardHours son constantes; se excluyen de los análisis junto al identificador, conservándolos en la fuente original.

Ficha de variables

Se distinguen tipos estadísticos y tipos de almacenamiento. Las escalas de satisfacción y nivel educativo son ordinales aunque sus códigos sean enteros. Edad y duraciones se clasifican como discretas por estar registradas en años enteros; los importes se tratan como continuos aunque estén redondeados. Las unidades monetarias y de distancia deben verificarse antes de interpretar magnitudes. No se asume moneda chilena.

Ficha completa de variables

BusinessTravel se trata como nominal; su frecuencia puede ordenarse explícitamente para presentar gráficos. Attrition y OverTime son nominales binarias. MonthlyIncome representa ingreso mensual; MonthlyRate es otra tarifa y no se intercambia con el ingreso.

Variable	Tipo estadístico
Age	Discreta, conteo o años enteros
Attrition	Cualitativa nominal
BusinessTravel	Cualitativa nominal
DailyRate	Continua para el análisis
Department	Cualitativa nominal
DistanceFromHome	Medida registrada en enteros
Education	Cualitativa ordinal
EducationField	Cualitativa nominal
EmployeeCount	Constante
EmployeeNumber	Identificador nominal
EnvironmentSatisfaction	Cualitativa ordinal
Gender	Cualitativa nominal
HourlyRate	Continua para el análisis
JobInvolvement	Cualitativa ordinal
JobLevel	Cualitativa ordinal
JobRole	Cualitativa nominal
JobSatisfaction	Cualitativa ordinal
MaritalStatus	Cualitativa nominal
MonthlyIncome	Continua para el análisis
MonthlyRate	Continua para el análisis
NumCompaniesWorked	Discreta, conteo o años enteros
Over18	Constante
OverTime	Cualitativa nominal
PercentSalaryHike	Medida registrada en enteros
PerformanceRating	Cualitativa ordinal
RelationshipSatisfaction	Cualitativa ordinal
StandardHours	Constante
StockOptionLevel	Cualitativa ordinal
TotalWorkingYears	Discreta, conteo o años enteros
TrainingTimesLastYear	Discreta, conteo o años enteros
WorkLifeBalance	Cualitativa ordinal
YearsAtCompany	Discreta, conteo o años enteros
YearsInCurrentRole	Discreta, conteo o años enteros
YearsSinceLastPromotion	Discreta, conteo o años enteros
YearsWithCurrManager	Discreta, conteo o años enteros

2 Aplicación de estadística descriptiva

Siguiendo el apunte de datasets, se generaron faltantes artificiales MCAR en MonthlyIncome y DistanceFromHome: 147 valores por variable, equivalentes al 10 %. Se seleccionaron posiciones sin reemplazo con `numpy.random.default_rng(42)`, sin utilizar magnitudes ni otras variables. Se conservaron las posiciones, el identificador y los valores originales para evaluar imputaciones futuras. En este informe no se imputan valores; se usan observaciones disponibles y se declara el tamaño efectivo.

Variable	n	Media	Mediana	DE	Q1	Q3
Age	1470	36.92	36.00	9.14	30.00	43.00
MonthlyIncome	1323	6530.21	4960.00	4708.33	2930.50	8404.00
DistanceFromHome	1323	9.18	7.00	8.09	2.00	14.00
YearsAtCompany	1470	7.01	5.00	6.13	3.00	9.00
TotalWorkingYears	1470	11.28	10.00	7.78	6.00	15.00

Tabla 1. Medidas sobre la versión con faltantes MCAR. DE corresponde a desviación estándar muestral.

Los importes se expresan en unidades del archivo.

La edad media es 36,92 años y la mediana es 36. La antigüedad media es 7,01 años y la mediana es 5, lo que evidencia una concentración en duraciones menores con algunos valores elevados. Para ingreso, la media de los valores observados es 6.530,21 y supera la mediana; junto al histograma, esto respalda la descripción de asimetría hacia la derecha. No se eliminan automáticamente los valores extremos.

Attrition	Frecuencia	Porcentaje
No	1233	83,88 %
Yes	237	16,12 %

El porcentaje de salida describe estos registros y no debe denominarse tasa anual, ya que no se establece un período de seguimiento. La clase objetivo está desbalanceada. Para satisfacción se reportan frecuencias: niveles 1, 2, 3 y 4 con 289, 280, 442 y 459 registros respectivamente; no se presupone igualdad de distancia entre niveles.

Representaciones gráficas




Figura 1. Barras del objetivo, histograma de ingreso, cajas por salida y porcentaje de salida por horas extra. Fuente: elaboración propia sobre el CSV y la versión MCAR.

Las barras muestran el desbalance del objetivo. El histograma y las cajas permiten examinar dispersión y asimetría del ingreso. Los puntos fuera de las cajas son observaciones extremas según la regla gráfica, no errores demostrados. El porcentaje de salida es mayor en el grupo con horas extra; esta comparación es descriptiva y requiere un contraste estadístico y cautela respecto de otros factores.

3 Estimación puntual e intervalos de confianza

Se estimó la proporción de salida con los 1.470 registros y el ingreso medio con 1.323 valores observados. Se usó Wilson para la proporción, que evita limitaciones del intervalo normal simple, y t de Student para el ingreso medio, con desviación poblacional desconocida. El análisis de la media se apoya en el tamaño muestral y en una aproximación de su distribución, aun cuando el ingreso individual sea asimétrico.

Parámetro	n	Estimación	IC del 95 %
Proporción de salida	1470	16,12 %	14,33 % a 18,09 %
Ingreso mensual medio	1323	6.530,21	6.276,27 a 6.784,15

El porcentaje de estos registros es exacto para el archivo. Los intervalos ilustran incertidumbre bajo un modelo hipotético de muestreo independiente del proceso sintético; no estiman parámetros de una empresa real. Bajo los supuestos, el procedimiento del 95 % cubre el parámetro en aproximadamente el 95 % de repeticiones. No se interpreta como una probabilidad del 95 % de que un parámetro fijo esté en este intervalo ya calculado.

4 Aplicación de una prueba de hipótesis

Se contrastó la independencia entre OverTime y Attrition mediante chi-cuadrado de Pearson sin corrección de continuidad, con $\alpha = 0,05$. H0: las variables son independientes bajo el modelo de análisis. H1: presentan asociación. Se asume independencia entre observaciones; la unicidad del identificador no basta para probarla.

Horas extra	Permaneció	Salió	Salida en el grupo
No	944	110	10,44 %
Yes	289	127	30,53 %

Todas las frecuencias esperadas superan 5; la mínima es 67,07. El resultado es $\chi^2 = 89,0439$; gl = 1; $p = 3,86 \times 10^{-21}$. Se rechaza H0. V de Cramér = 0,2461 cuantifica la intensidad de la asociación. La diferencia descriptiva es 20,09 puntos porcentuales; la significancia estadística no equivale por sí sola a importancia práctica.

El análisis es bivariado y exploratorio: no controla cargo, antigüedad, ingreso u otras condiciones que podrían explicar parte del patrón. Los resultados no demuestran que las horas extra causen la salida.

5 Documentación de procedimientos y resultados

El análisis se reproduce con `Formativa1_IBM_HR_Paso_a_Paso.ipynb`, ubicado en la carpeta `Formativa1` del repositorio, y `WA_Fn-UseC_-HR-Employee-Attrition.csv`, ubicado en la carpeta `datos`. El notebook carga el archivo mediante una ruta relativa, se ejecuta secuencialmente y utiliza `pandas`, `NumPy`, `SciPy`, `Matplotlib` y `seaborn`. El archivo original se conserva intacto y los faltantes se generan desde una copia en cada ejecución, evitando su acumulación.

Etapas	Procedimiento
Calidad	<code>shape</code> , <code>isna</code> , <code>uplicated</code> , <code>nunique</code> y revisión del identificador
Clasificación	Separación de nominales, ordinales, cantidades e identificadores
MCAR	147 posiciones aleatorias por columna; semilla 42; originales reservados
Descriptiva	<code>describe</code> y agrupación por <code>Attrition</code> ; <code>n</code> efectivo por variable
Estimación	Wilson para proporción; <code>scipy.stats.t.interval</code> para media
Hipótesis	<code>crosstab</code> y <code>chi2_contingency</code> con <code>correction=False</code> ; <code>V</code> de Cramér

La trazabilidad del análisis se mantiene mediante el notebook con código y resultados, el registro de las versiones de Python y bibliotecas en su celda inicial y el repositorio indicado en la portada. La versión con faltantes MCAR y los valores originales retirados se conservan en memoria durante la ejecución. Estos valores se reservan para evaluar imputaciones posteriores y no se utilizan para completar las medidas de esta entrega.

6 Interpretación preliminar de resultados

El patrón más claro es la mayor proporción de salida entre registros con horas extra: 30,53 % frente a 10,44 %. La prueba confirma asociación bajo los supuestos de análisis. Como orientación para una investigación posterior, conviene examinar carga laboral, distribución de horas extra y condiciones de los cargos antes de proponer intervenciones. No se recomienda una política empresarial definitiva a partir de datos sintéticos.

El desbalance del objetivo será relevante en fases predictivas: una alta exactitud podría ocultar un desempeño bajo para la clase de salida. Las diferencias de ingreso deben leerse considerando asimetría, cargo y antigüedad. Los faltantes generados permiten estudiar imputación en etapas posteriores, pero reducen ahora la información disponible sobre ingreso y distancia.

Las limitaciones centrales son la naturaleza sintética, ausencia de marco de muestreo y período definidos, asociación bivariada sin ajuste y falta de evidencia causal. El informe aporta una práctica de decisiones bajo incertidumbre, cuyo traslado a una organización exige datos reales y validación contextual.

Referencias

Maidana, J. P. (2026). Bases de datos disponibles para el proyecto del curso [Apunte]. Universidad Andrés Bello.

Maidana, J. P. (2026, 6 de octubre). Semana 1 Inicio del Proyecto ABP [Diapositivas]. Universidad Andrés Bello.

jpmaidana. (s. f.). MCDI501-202682 [Repositorio de materiales del curso]. GitHub.

<https://github.com/jpmaidana/MCDI501-202682>

pavansubhasht. (s. f.). IBM HR Analytics Employee Attrition & Performance [Conjunto de datos].

Kaggle. <https://www.kaggle.com/datasets/pavansubhasht/ibm-hr-analytics-attrition-dataset>