MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

MCDI501: Estadística Computacional para la Toma de Decisiones

Evaluación Sumativa 3

Modelamiento Predictivo Integrado

Informe técnico grupal · 60 %

Título del proyecto:	Rotación de personal mediante modelamiento predictivo integrado
Integrantes:	Hernán Saavedra · Lenin Morales · Rodrigo Gómez
Dataset:	IBM HR Employee Attrition
Docente:	Equipo docente MCDI501
Fecha:	28/10/2026
Repositorio GitHub:	https://github.com/hernansaavedrag/estadisticaComputacional

Índice

Resumen ejecutivo....3
Introducción y metodología integrada....3
1 Continuidad entre S1 S2 y S3....3
2 Manejo de datos faltantes....4
2.1 Regresión de imputación y diagnósticos....4
2.2 Comparación y estrategia elegida....4
3 Selección y diagnóstico de modelos logísticos....5
3.1 Validación y ponderación....5
3.2 Diagnósticos y sensibilidad a influencia....5
4 Coeficientes y estabilidad mediante bootstrap....6
5 Evaluación predictiva....7
6 Impacto de la imputación y conclusiones....8
6.1 Discusión y recomendaciones....8
Bibliografía y acceso a los entregables....9
Acceso al proyecto y presentación....9

Resumen ejecutivo

Se desarrolló un flujo integrado para discriminar la salida de empleados en IBM HR Employee Attrition, con 1.470 registros sintéticos y 16,12 % de salidas. S1 caracterizó asociaciones; S2 examinó estabilidad y sensibilidad; S3 comparó imputación, selección de modelos, ponderación y estabilidad de coeficientes.

La imputación por regresión redujo el error frente a mediana en validación de entrenamiento y conservó todos los registros. El modelo propuesto, M2c ponderado, detectó 52 de 71 salidas de prueba: recall 73,24 %, precision 36,36 %, F1 0,4860 y AUC 0,7722. Frente a F2 aumentó la detección y las falsas alarmas, sin mejorar sustancialmente el AUC. El bootstrap de 10.000 réplicas respaldó la dirección de los predictores salvo Human Resources. El alcance es académico y exploratorio.

Introducción y metodología integrada

La pregunta del proyecto es qué características permiten discriminar entre empleados que permanecen y quienes salen. Attrition contiene 237 salidas y 1.233 permanencias. Los datos son sintéticos, sin marco de muestreo empresarial ni horizonte temporal documentado; por ello no se interpretan como tasas futuras ni evidencia causal (pavansubhasht, s. f.).

1 Continuidad entre S1 S2 y S3

Evidencia de S1/S2	Decisión en S3
Salida con horas extra 30,53 % frente a 10,44 %; $\chi^2 = 89,04$; V = 0,246.	Incluir OverTime en M1 y como candidata para selección.
Diferencia media de ingreso: 2.045,65; IC Welch [1.508,24; 2.583,05]. S2 conservó la dirección con bootstrap de medias y medianas.	Considerar ingreso y evaluar sensibilidad a su imputación.
Spearman ingreso–experiencia 0,710; IC BCa [0,679; 0,739]. Relaciones edad–experiencia y antigüedad–experiencia también estables.	Fundamentar la regresión de imputación y revisar redundancias.
La exclusión de ingresos altos redujo la diferencia media cerca de 39 %; su dirección se mantuvo.	Conservar extremos en el análisis principal y evaluar influencia.
Monte Carlo de S2, con parámetros fijos, produjo media 236,90 salidas y rango central [210; 264].	Reconocer incertidumbre simulada; no interpretar el escenario como pronóstico temporal.

Tabla 1. Evidencia previa y decisiones del modelamiento.

La Tabla 1 sintetiza la progresión metodológica, sin repetir los análisis completos (Saavedra et al., 2026a, 2026b). F2 aportó el primer modelo y una advertencia: accuracy 84,35 % coexistía con recall de apenas 5,63 %. Esta limitación motivó evaluar ponderación en S3.

Reproducibilidad: notebook maestro S3/notebooks/S3_IBM_HR_Proyecto_Final.ipynb, dependencias en S3/requirements.txt y funciones en S3/src. Se conservaron datos MCAR, identificadores de partición, resultados y lotes bootstrap. El notebook maestro tiene 44 celdas de código ejecutadas consecutivamente.

2 Manejo de datos faltantes

El dataset original de S1/S2 no tenía faltantes. Por indicación docente, en F2 se ocultaron 147 ingresos (10 %) mediante selección aleatoria sin reemplazo y semilla 42, mecanismo MCAR por construcción. S3 reutiliza esa versión y la partición estratificada 70/30: 1.029 registros de entrenamiento y 441 de prueba; 96 y 51 ingresos faltantes, respectivamente. Attrition no se imputa ni se usa para imputar.

2.1 Regresión de imputación y diagnósticos

Se ajustó MonthlyIncome sobre TotalWorkingYears, Age y YearsAtCompany con intercepto, usando 933 ingresos observados de entrenamiento. El R^2 fue 0,604; los VIF, 2,897, 1,980 y 1,684. Los coeficientes fueron 467,97 para experiencia, −15,36 para edad y 17,89 para antigüedad; el IC HC3 de experiencia [414,50; 521,44] excluye cero, mientras los otros dos lo incluyen.

Breusch–Pagan mostró heterocedasticidad (LM = 183,91; $p = 1{,}26 \times 10^{-39}$). Los residuos y Q-Q se documentan en el notebook. HC3 complementa la inferencia, pero no modifica predicciones ni corrige toda la especificación. La independencia se asume, no se demuestra con estos diagnósticos. No se generaron ingresos imputados no positivos.

2.2 Comparación y estrategia elegida

Estrategia	N train/test	MAE / RMSE CV	MAE / RMSE ocultados test	Sesgo test
Eliminación	933 / 390	No aplica	No aplica	No aplica
Mediana	1.029 / 441	3.308,30 / 4.848,16	3.123,86 / 4.821,22	-950,69
Regresión	1.029 / 441	2.174,84 / 2.923,40	2.215,69 / 2.907,98	141,94

Tabla 2. Tamaños y evaluación del error de imputación.

La validación cruzada de cinco pliegues sobre entrenamiento observado recalculó regresión y mediana dentro de cada ajuste. La Tabla 2 muestra reducciones de MAE de 34,3 % y RMSE de 39,7 %. En los 96 ocultados de entrenamiento, los MAE fueron 3.322,04 y 2.260,28, y los sesgos −1.317,79 y −208,92, para mediana y regresión. La eliminación no produce valores imputados; su error no aplica.

Se eligió regresión exclusivamente con evidencia de entrenamiento. Los 51 ocultados de prueba se reservaron para evaluación final. La media imputada en entrenamiento fue 6.528,78 frente a 6.548,27 original, y la DE 4.511,05 frente a 4.611,46. La correlación ingreso–experiencia aumentó de 0,713 a 0,735: la imputación determinista reduce variabilidad residual y puede reforzar relaciones. No se afirma preservación exacta ni equivalencia entre estrategias.

3 Selección y diagnóstico de modelos logísticos

Se mantuvo la partición de F2. Se codificó salida como 1; OverTime como 0/1 y Department mediante indicadoras, referencia Research & Development. Las variables numéricas se estandarizaron con parámetros de entrenamiento. JobSatisfaction se trató inicialmente como puntuación ordinal lineal; EmployeeNumber se usó solo para alinear registros.

Las candidatas fueron las cuatro de F2 más edad, experiencia total, distancia, nivel laboral y departamento. Su fundamento y la trayectoria de selección están documentados en el notebook. Department entró y salió como bloque. AIC/BIC se compararon en ajustes sin ponderar sobre las mismas 1.029 observaciones.

Modelo	Variables incluidas	k	AIC	BIC
M1	Horas extra, ingreso, antigüedad y satisfacción.	5	814,17	838,85
M2	Stepwise AIC: horas extra, antigüedad, satisfacción, edad, distancia, nivel laboral y departamento.	9	780,79	825,21
M3	Mejor subconjunto BIC: horas extra, antigüedad, satisfacción, edad y departamento.	7	788,66	823,21
M2c	Variante de M2: ln(1+antigüedad), ln(edad) e indicador nivel 1; conserva las otras variables.	9	748,07	792,50

Tabla 3. Especificaciones y criterios de información sin ponderar.

Ingreso y JobLevel presentaron VIF cercanos a 7,8 juntos en las candidatas; M2 retuvo JobLevel y excluyó ingreso. Los VIF finales de M2c no superaron 1,55. La Tabla 3 presenta M2c como extensión diagnóstica, no como sustitución de los tres modelos requeridos.

3.1 Validación y ponderación

Se utilizó validación estratificada 5 × 5 dentro de entrenamiento. En cada pliegue se reajustaron imputación, estandarización, pesos y selección AIC/BIC. Los pesos n/(2n_clase) fueron aproximadamente 0,596 para permanencia y 3,099 para salida. Las versiones ponderadas utilizaron GLM binomial y covarianza sándwich HC0; los pesos no representan frecuencias reales.

M2 ponderado obtuvo AUC medio 0,747 y F1 0,415, frente a 0,732/0,408 de M1 y 0,727/0,401 de M3. Una regla orientativa de recall ≥ 0,50, proximidad de AUC/F1 y complejidad propuso M2. Los errores estándar entre pliegues repetidos no son intervalos independientes.

Los diagnósticos motivaron M2c. Con especificaciones fijas obtuvo AUC 0,777, recall 0,707 y F1 0,449 en validación. Las transformaciones se eligieron mirando todo el entrenamiento: esta comparación es exploratoria y potencialmente optimista. No permite cuantificar el optimismo ni valida de forma independiente toda la selección. Prueba no se usó para cambiar el modelo propuesto.

3.2 Diagnósticos y sensibilidad a influencia

Box–Tidwell de M2c mostró curvatura residual para ln(1+antigüedad), p = 0,034; edad transformada y distancia no mostraron evidencia con esa prueba. La codificación lineal de satisfacción no se rechazó (p = 0,649). Hosmer–Lemeshow del ajuste sin ponderar dio p = 0,113, sin probar por ello calibración perfecta. Al excluir conjuntamente diez casos influyentes, los OR conservaron dirección, pero horas extra y Sales cambiaron cerca de 30 % y 31 %. Se conservaron todos los casos; no se concluye ausencia de influencia individual.

4 Coeficientes y estabilidad mediante bootstrap

Se realizaron 10.000 remuestras con reemplazo del entrenamiento MCAR, con flujos reproducibles por réplica, repitiendo imputación, escalado, pesos y ajuste. Se guardaron lotes reanudables y se registraron 10.000 ajustes válidos, sin advertencias ni fallos registrados. La especificación se mantuvo fija; el alcance es condicional a las variables y transformaciones elegidas.

Las pendientes bootstrap se convirtieron a la DE del entrenamiento original, ajustando también intercepto y escala de comparación. Los intervalos percentiles se contrastaron con HC0. Para variables transformadas, una DE corresponde a la escala logarítmica, no a una DE de años originales.

Predictor	β	IC HC0	IC bootstrap	Signo (%)
Horas extra	1,360	[0,961; 1,759]	[0,980; 1,801]	100,00
ln(1+antigüedad)	-0,320	[-0,534; -0,105]	[-0,550; -0,103]	99,77
Satisfacción	-0,303	[-0,491; -0,115]	[-0,506; -0,121]	99,90
ln(edad)	-0,271	[-0,492; -0,050]	[-0,509; -0,053]	99,37
Distancia	0,241	[0,052; 0,430]	[0,048; 0,436]	99,20
Nivel 1	1,097	[0,590; 1,605]	[0,599; 1,648]	100,00
HR frente a R&D	0,338	[-0,406; 1,083]	[-0,579; 1,043]	78,39
Sales frente a R&D	1,202	[0,717; 1,686]	[0,731; 1,730]	100,00

Tabla 4. Coeficientes, intervalos del 95 % y conservación del signo.

Predictor	OR	IC OR HC0	IC OR bootstrap
Horas extra	3,895	[2,614; 5,806]	[2,664; 6,053]
ln(1+antigüedad)	0,726	[0,586; 0,900]	[0,577; 0,902]
Satisfacción	0,739	[0,612; 0,891]	[0,603; 0,886]
ln(edad)	0,763	[0,612; 0,951]	[0,601; 0,948]
Distancia	1,273	[1,053; 1,538]	[1,049; 1,547]
Nivel 1	2,996	[1,803; 4,977]	[1,821; 5,197]
HR frente a R&D	1,402	[0,666; 2,952]	[0,560; 2,838]
Sales frente a R&D	3,326	[2,049; 5,399]	[2,076; 5,639]

Tabla 5. Odds ratios e intervalos del 95 % del modelo ponderado.

En las Tablas 4 y 5, HR incluye cero en el coeficiente y 1 en el OR; conserva signo positivo en 78,39 %. Los otros predictores conservan dirección en al menos 99,20 %. Los métodos de intervalo concuerdan en qué predictores incluyen el valor nulo; el intervalo bootstrap de HR es más amplio por su extremo inferior.

Horas extra compara sí/no: OR 3,90. Nivel 1 compara con niveles 2–5: OR 3,00. Sales compara con R&D: OR 3,33. Para las continuas, +1 DE implica OR 1,27 en distancia y 0,74 en satisfacción. En ln(1+antigüedad), multiplicar (1+años) por 2,12 implica OR 0,73; en ln(edad), multiplicar edad por 1,28 implica OR 0,76. Son cambios en odds, no porcentajes de cambio de probabilidad; no se comparan magnitudes sin atender a sus unidades.

5 Evaluación predictiva

Modelo	Conjunto	Accuracy	Precision	Recall	F1	AUC
M1	Train	0,694	0,300	0,675	0,416	0,736
M1	Test	0,730	0,342	0,732	0,466	0,773
M2	Train	0,705	0,312	0,693	0,431	0,767
M2	Test	0,723	0,331	0,704	0,450	0,761
M3	Train	0,702	0,308	0,681	0,424	0,760
M3	Test	0,723	0,324	0,662	0,435	0,746
M2c	Train	0,730	0,342	0,729	0,465	0,791
M2c	Test	0,751	0,364	0,732	0,486	0,772

Tabla 6. Desempeño ponderado con umbral 0,5.

La Tabla 6 describe todos los modelos; no modifica la selección previa. M2c detecta 52 de 71 salidas (TP), omite 19 (FN), acierta 279 permanencias (TN) y genera 91 falsas alarmas (FP). Su precision de 36,36 % significa que alrededor de uno de cada tres empleados marcados efectivamente sale. El F1 es 0,486 y el AUC 0,7722 indica discriminación aceptable según la referencia docente, no accuracy de 77 %.

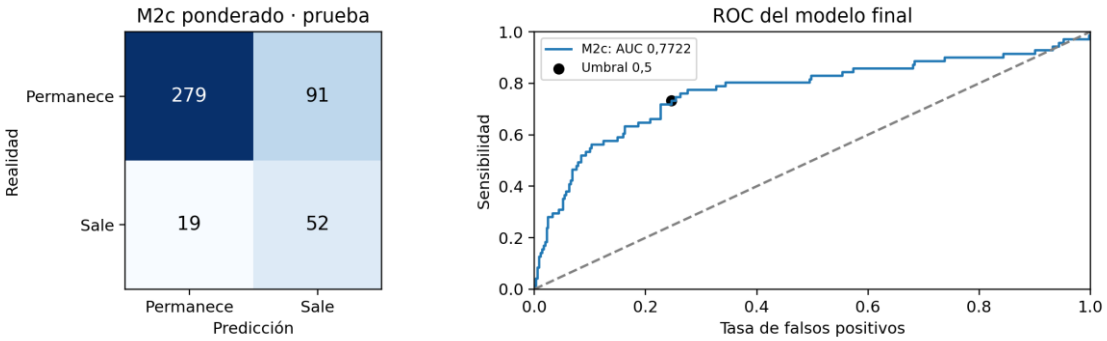


Figura 1. Matriz de confusión y ROC de M2c ponderado en prueba. Las ROC comparadas de todos los modelos y las matrices train/test se conservan en el notebook.

Frente a F2, recall pasa de 5,63 % a 73,24 %, pero las falsas alarmas aumentan de 2 a 91 y accuracy baja de 84,35 % a 75,06 %. M2c sin ponderar alcanza recall 23,94 %, precision 62,96 % y AUC 0,7728; ponderar cambia el punto operativo más que la discriminación. La comparación F2–S3 combina especificación, imputación y pesos. Las puntuaciones ponderadas no deben leerse como probabilidades poblacionales; la versión sin ponderar tampoco garantiza calibración.

6 Impacto de la imputación y conclusiones

Modelo	Estrategia	N train	Accuracy	Recall	F1	AUC
M1	eliminacion	933	0,736	0,769	0,493	0,803
M1	mediana	1029	0,726	0,769	0,483	0,804
M1	regresion	1029	0,733	0,769	0,490	0,803
M2c	eliminacion	933	0,746	0,723	0,487	0,796
M2c	mediana	1029	0,756	0,754	0,508	0,802
M2c	regresion	1029	0,756	0,754	0,508	0,802

Tabla 7. Evaluación sobre los mismos 390 empleados de prueba.

La Tabla 7 usa los identificadores de prueba de la estrategia de eliminación; no selecciona las primeras 390 filas. En prueba disponible, eliminación evalúa 390 empleados y las imputaciones 441; esos resultados completos también están exportados. Los AUC del subconjunto común no se comparan directamente con los de 441 personas.

Estrategia	β	IC β HC0	OR	IC OR HC0
eliminacion	-0,413	[-0,629; -0,197]	0,662	[0,533; 0,821]
mediana	-0,398	[-0,615; -0,182]	0,671	[0,541; 0,834]
regresion	-0,377	[-0,590; -0,164]	0,686	[0,554; 0,849]

Tabla 8. Sensibilidad del ingreso en M1, en una escala común.

M2c no incluye ingreso: mediana y regresión dan el mismo ajuste porque conservan filas y predictores idénticos. La eliminación cambia el entrenamiento y, por tanto, puede cambiar coeficientes. La Tabla 8 complementa con M1: el ingreso mantiene dirección negativa y los tres IC OR excluyen 1; las métricas son poco sensibles en los escenarios examinados, sin demostrar equivalencia formal. Se transformaron coeficientes y covarianzas a la media y DE de la estrategia de regresión para evitar confundir unidades con cambios de asociación.

6.1 Discusión y recomendaciones

Las asociaciones exploratorias de S1 guiaron candidatas; S2 distinguió estabilidad de dirección y sensibilidad de magnitud; S3 mostró que una mayor detección exige aceptar más falsas alarmas. Horas extra, nivel de entrada, departamento y trayectoria contribuyen a discriminar salida en este ejercicio. El ingreso sigue asociado en M1; su exclusión por selección no demuestra irrelevancia causal.

Se recomienda conservar el flujo reproducible y los extremos sin errores demostrados, examinar calibración, definir costos de omisión y falsa alarma, validar umbrales dentro de entrenamiento y contrastar el modelo con datos reales independientes antes de cualquier uso operativo. La incertidumbre de imputación y selección debe ampliarse en futuras validaciones.

Limitaciones: datos sintéticos; reutilización exploratoria de prueba desde F2; transformaciones elegidas con entrenamiento completo; bootstrap condicional a una especificación fija; heterocedasticidad y curvatura residual; categorías pequeñas e influencia apreciable de algunos casos. Ninguna de estas verificaciones establece causalidad ni justifica políticas reales de personal.

Bibliografía y acceso a los entregables

Maidana, J. P. (2026). Guía para la presentación final [Apunte]. Universidad Andrés Bello.

pavansubhasht. (s. f.). IBM HR Analytics Employee Attrition & Performance [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/pavansubhasht/ibm-hr-analytics-attrition-dataset

Saavedra, H., Morales, L., & Gómez, R. (2026a). Sumativa 1: análisis exploratorio e inferencial de IBM HR Employee Attrition [Informe y notebook académico]. Universidad Andrés Bello. https://github.com/hernansaavedrag/estadisticaComputacional/tree/main/S1

Saavedra, H., Morales, L., & Gómez, R. (2026b). Sumativa 2: validación mediante simulación y remuestreo [Informe y notebook académico]. Universidad Andrés Bello. https://github.com/hernansaavedrag/estadisticaComputacional/tree/main/S2

Saavedra, H., Morales, L., & Gómez, R. (2026c). Sumativa 3: modelamiento predictivo integrado de rotación de personal [Notebook académico]. Universidad Andrés Bello. https://github.com/hernansaavedrag/estadisticaComputacional/tree/main/S3

Acceso al proyecto y presentación

Repositorio: https://github.com/hernansaavedrag/estadisticaComputacional

Notebook maestro de esta entrega: https://github.com/hernansaavedrag/estadisticaComputacional/blob/main/S3/notebooks/S3_IBM_HR_Proyecto_Final.ipynb

Presentación grupal: https://drive.google.com/file/d/11QPoWrNfOXjnenUXY9j4jeQAH7_TKVL2/view?usp=sharing

Las tablas de este informe provienen de los CSV exportados por el notebook maestro. Se preservan los resultados de imputación, selección, diagnósticos, desempeño y bootstrap en S3/resultados; las figuras, en S3/figuras. Los lotes de bootstrap se verifican mediante huella de datos y configuración.